中国科学技术大学

本科毕业论文

人形机器人遥操作与通用全身运动控制研究

作者姓名: 祁川

学　　号: PB22081549

专　　业: 自动化系

导　　师: 尚伟伟教授　陈凯研究员

完成时间: 2026 年 4 月 30 日

中国科学技术大学本科毕业论文学术诚信承诺书

本人郑重承诺：所呈交的本科毕业论文，是本人在导师指导下进行研究工作所取得的成果。除已特别加以标注和致谢的地方外，论文中不包含任何他人已经发表或撰写过的研究成果。与我一同工作的同志对本研究所做的贡献均已在论文中作了明确的说明。如出现侵犯他人知识产权的行为，由本人承担相应法律责任。本人承诺不存在抄袭、伪造、篡改、代写、买卖毕业论文 (设计) 等违纪行为。

作者签名：_____

签字日期：_____

摘 要

人形机器人被认为是具身智能的重要载体，其在家庭服务、公共服务、灾害救援和高风险作业等场景中具有广阔应用前景。与传统机械臂或轮式移动平台相比，人形机器人需要在高维、强耦合和欠驱动条件下完成稳定移动与灵巧操作，因此全身运动控制一直是该领域的核心难题。围绕这一问题，本文以“人在回路”的研究范式为主线，尝试打通从人体动作采集、动作重定向、控制策略生成到感知驱动任务执行的完整技术链路，为人形机器人的通用全身运动控制提供一套可复用的实现框架。

在数据采集层，本文构建了面向人形机器人遥操作的数据获取体系，综合利用 Noitom 惯性动捕、Nokov 光学动捕以及基于 SONIC 框架的仿真交互过程，覆盖从高自由度人体动作到复杂人机交互轨迹的多源异构数据。针对人体与机器人在骨骼长度、关节布局和自由度上的差异，进一步设计了基于 GMR 的运动重定向方法，将人体动作统一映射到 Unitree G1 及全尺寸机器人平台的可执行轨迹空间，为后续控制策略训练与真机部署提供稳定的数据基础。

在控制策略层，本文提出了上下肢解耦的通用全身运动控制框架。下肢部分采用单一命令条件强化学习策略，在连续速度命令驱动下实现前进、后退、原地转向和左右平移等基础 locomotion 行为，并通过 motion prior、imitation 与强化学习混合训练，以及域随机化和参数适配提升仿真到真实系统的迁移能力。上肢部分则以遥操作数据接口和逆运动学求解为核心，实现对上肢目标轨迹的高保真跟踪，并通过重心补偿和冲突处理机制完成全身协调控制，从而兼顾移动稳定性与操作精度。

在任务验证层，本文开发了感知–控制闭环系统，并在两个代表性任务中验证所提方法的有效性。在 CyboRacket 动态球拍任务中，视觉系统对高速目标进行检测和轨迹预测，控制系统据此完成下肢导航、上肢挥拍和全身协同动作生成；在 OpenClaw 语音服务任务中，高层任务规划与视觉感知模块输出结构化子任务和目标位姿信息，控制框架进一步完成导航、抓取与递送等动作执行。实验与系统集成结果表明，本文所提出的技术路线能够有效支撑人形机器人从遥操作数据采集到自主任务执行的闭环应用。

关键词：人形机器人；全身运动控制；遥操作；强化学习；感知控制闭环

ABSTRACT

Humanoid robots are widely regarded as an important embodiment of embodied intelligence, with strong application potential in household service, public assistance, disaster response, and other complex scenarios. Compared with traditional robotic manipulators or wheeled platforms, humanoid systems must accomplish stable locomotion and dexterous manipulation under high-dimensional, strongly coupled, and underactuated conditions. Whole-body motion control therefore remains a central challenge. To address this problem, this thesis follows a human-in-the-loop paradigm and aims to establish an end-to-end technical pipeline spanning motion capture, motion retargeting, control policy generation, and perception-driven task execution.

On the data acquisition side, a multi-source teleoperation data collection system is constructed by integrating Noitom inertial motion capture, Nokov optical motion capture, and simulation-based interaction data generated within the SONIC framework. This design covers both high-degree-of-freedom human motion and complex loco-manipulation trajectories. To bridge the morphological gap between humans and humanoid robots, including differences in limb length, joint layout, and actuation space, a GMR-based motion retargeting method is further introduced to map human motion into executable trajectories for the Unitree G1 platform and full-scale humanoid robots.

On the control side, this thesis proposes a decoupled whole-body control framework in which the lower body focuses on locomotion stability and the upper body focuses on manipulation accuracy. The lower body is driven by a single command-conditioned reinforcement learning policy that realizes forward motion, backward motion, in-place turning, and lateral translation under continuous velocity commands. Motion prior constraints together with mixed imitation and reinforcement learning are introduced to preserve natural gait structure, while domain randomization and parameter adaptation are employed to improve sim-to-real transfer. The upper body relies on teleoperation interfaces and inverse kinematics solvers to track target trajectories with high fidelity. Whole-body coordination is achieved through conflict handling and center-of-mass compensation mechanisms, enabling stable and flexible combined motions.

On the task validation side, a perception-control closed-loop system is developed and evaluated in two representative scenarios. In the CyboRacket dynamic racket task, the vision module detects and predicts high-speed targets, and the proposed controller generates coordinated lower-body navigation and upper-body striking motions. In the OpenClaw voice-commanded service task, high-level planning and visual perception provide structured subtasks and target poses, while the whole-body controller executes navigation, grasping, and delivery behaviors. The resulting system demonstrates that the proposed pipeline can effectively support humanoid robots from teleoperation data acquisition to autonomous task execution.

Key Words: Humanoid Robots; Whole-Body Control; Teleoperation; Reinforcement Learning; Perception-Control Loop

目　录

第一章　绪论 5
第一节　研究背景与意义 5
第二节　国内外研究现状 5
一、遥操作与数据采集 5
二、通用全身运动控制 6
三、感知–控制闭环与自主任务 6
第三节　本文主要研究内容 7
第四节　论文组织结构 8

第二章　多源全身运动数据采集与重定向 9
第一节　系统架构概述 9
第二节　多源人体运动捕捉系统 10
一、惯性动捕系统 10
二、光学动捕系统 10
三、机器人-物体交互数据采集 10
第三节　基于 GMR 的重定向 12
一、GMR 算法介绍 12
二、基于 GMR 的多源数据重定向实现 12
三、多平台适配：G1 与 Taihu 全尺寸机器人 13

第三章　解耦式通用全身运动控制策略 15
第一节　上下肢解耦控制架构设计 15
第二节　上肢遥操作 16
一、系统组成与数据流 16
二、基于 PICO 的双臂目标位姿获取 17
三、双臂逆运动学求解方法 18
四、Taihu 平台迁移与仿真验证 19
第三节　下肢强化学习 Locomotion 策略 20
一、任务建模与训练环境 20

二、命令输入、观测与动作设计 21
三、奖励函数与终止条件设计 22
四、策略优化与训练配置 24
五、单一命令条件策略与训练效果 24
第四节　系统集成与真机验证 26
一、连续命令输入与 PICO 控制接口 26
二、上下肢解耦融合与统一控制输出 27
三、真机任务验证 27

第四章　感知–控制闭环的自主任务执行 29
第一节　感知–控制闭环架构概述 29
第二节　动态球拍运动控制任务 29
一、任务背景与系统架构 29
二、视觉感知与轨迹预测接口 30
三、全身运动生成与实验验证 30
第三节　语音指令服务任务执行 30
一、系统架构与任务流程 30
二、任务规划与视觉感知 31
三、全身控制集成与执行 31
四、实验验证 31
第四节　本章小结 32

第五章　结论与展望 33
第一节　本文工作总结 33
第二节　主要创新点 34
第三节　未来工作展望 34

参考文献 35
附录 A　硬件平台参数 36
第一节　Unitree G1 机器人平台 36
第二节　遥操作与感知设备 36
附录 B　强化学习训练超参数 37
第一节　PPO 训练配置 37

第二节　网络结构与训练环境 37
第三节　奖励、观测噪声与终止条件参数 38
致谢 40

插图和附表清单

图 2.1　多源动捕数据到机器人平台的 GMR 重定向框架示意图 9
图 3.1　解耦式通用全身运动控制架构图 16
图 3.2　PICO 遥操作输入与位姿获取通信数据流图 18
图 3.3　单一命令条件下肢策略训练流程图 21
图 3.4　单一命令条件策略训练曲线预留图位 25
图 3.5　单一命令条件策略仿真效果预留图位 25
图 3.6　单一命令条件策略真机效果预留图位 26
图 3.7　系统真机任务验证预留图位 28
表 2.1　机器人–物体交互数据采集中的代表性文件与关键字段 11
表 A.1　Unitree G1 平台关键参数占位表 36
表 B.1　PPO 训练超参数配置表 37
表 B.2　网络结构与训练环境配置表 38
表 B.3　命令奖励、观测噪声与终止条件参数表 39

第一章　绪论

第一节　研究背景与意义

人形机器人兼具类人的运动形态与任务交互能力，被普遍认为是具身智能系统迈向通用场景的重要平台。与轮式机器人相比，人形机器人能够适应楼梯、狭窄通道和以人类尺度设计的工作环境；与固定机械臂相比，人形机器人又天然具备移动能力和更大的操作工作空间，因此在家庭服务、工业巡检、灾害救援以及危险环境替代作业等场景中展现出显著潜力。

然而，人形机器人要真正进入开放环境并执行复杂任务，首先必须解决全身运动控制问题。该问题同时面临高自由度、动力学强耦合、接触切换频繁以及系统欠驱动等多重挑战。下肢需要维持稳定步态和抗扰平衡，上肢需要完成灵巧操作和精确跟踪，而二者在质心变化、关节力矩分配和接触约束方面又彼此影响。传统依赖模型推导和人工设计的控制方法虽然具有较好的可解释性，但面对复杂场景、多任务切换以及高自由度形态时，往往难以兼顾稳定性、灵活性与开发效率。

在这一背景下，“人在回路”的研究范式为人形机器人控制提供了一条兼顾数据效率与任务落地的新路径。通过遥操作系统获取高质量人体动作数据，可以显著降低复杂技能构建的门槛；通过动作重定向与控制接口设计，可以将人体示教经验迁移到机器人平台；进一步结合强化学习和感知闭环控制，则能够推动系统从“人控执行”发展到“自主执行”。因此，围绕遥操作数据采集、全身控制策略和任务级闭环验证建立统一技术链路，不仅具有重要理论意义，也对推动人形机器人走向真实应用具有工程价值。

第二节　国内外研究现状

一、遥操作与数据采集

遥操作是连接人类动作能力与机器人执行能力的重要桥梁，也是当前构建高质量具身数据集的重要手段。已有工作通常通过 VR 设备、惯性传感器、光学动捕系统或力反馈装置采集人体运动信息，并将其映射到机械臂、双臂平台或移动操作机器人。此类方法在示教采集、快速验证和远程控制方面效果显著，但在

面向人形机器人的全身场景时仍面临若干问题。

首先，不同采集设备的精度、延迟和部署成本差异较大，单一数据源往往难以同时覆盖高精度研究、日常采集与复杂交互任务三类需求。其次，人体与机器人之间普遍存在形态差异，包括肢体长度不一致、关节自由度不同以及执行约束不一致等，若缺乏统一的重定向机制，直接映射很容易造成动作失真、轨迹突变或关节超限。再次，当前不少系统更侧重上肢操作或局部动作采集，对移动与操作耦合的全身行为支持仍不充分。

因此，面向人形机器人的遥操作系统需要同时考虑多源数据接入、形态差异建模与机器人可执行性约束。本文针对上述问题构建多源人体运动捕捉体系，并以 GMR 为核心建立统一动作重定向框架，提升从人体动作到机器人动作的可迁移性与一致性。

二、通用全身运动控制

全身运动控制的目标是在满足接触约束和稳定性要求的前提下，使机器人协调完成移动、平衡和操作等行为。传统方法多依赖动力学模型、优化求解器以及分层控制架构，通过逆动力学、QP 优化或模型预测控制等方法实现任务优先级分配。这类方法在规则场景中具有较强稳定性，但在复杂接触、多样动作和高维策略搜索方面通常需要大量模型调参与任务定制。

随着强化学习在机器人领域的广泛应用，越来越多工作尝试利用仿真训练获得鲁棒步态和复杂运动技能。强化学习方法能够在大规模并行环境中自动搜索控制策略，尤其适合下肢步态生成和抗扰动控制。然而，完全端到端的全身策略训练通常需要更高训练成本，也对奖励设计、状态表征和仿真真实性提出更高要求。此外，端到端全身策略在上肢精细操作方面不一定具备足够优势，且策略解释性和工程调试难度较高。

因此，一种兼顾稳定移动与灵巧操作的可行路径是采用上下肢解耦的控制设计思路：下肢以强化学习获得通用 Locomotion 能力，上肢以轨迹跟踪和逆运动学保证操作精度，再通过统一接口实现全身协调。本文即基于这一思路设计通用全身运动控制框架，在系统层面平衡灵活性、鲁棒性和可部署性。

三、感知–控制闭环与自主任务

仅具备离线控制能力的人形机器人仍难以在开放环境中稳定执行任务。为了实现真正的自主作业，系统必须能够感知外界状态、理解任务目标、实时生成

控制指令并根据反馈持续修正行为。近年来，视觉感知、语音理解、大模型规划与机器人控制的结合推动了感知–控制闭环系统的发展，使机器人逐步具备从目标识别到任务执行的端到端能力。

在动态交互任务中，感知模块通常需要以较高频率完成目标检测、状态估计与轨迹预测，控制模块则需要在严格时延约束下生成全身动作；在服务型任务中，高层规划器需要将自然语言指令分解为结构化子任务，视觉模块需要输出可用于抓取和导航的目标位姿，而底层控制器则负责在动态环境中完成移动、抓取和递送。尽管相关研究不断推进，但感知输出与全身控制接口之间仍常存在抽象层级不一致、执行链路不统一和系统复用性不足的问题。

本文关注的不是单一感知算法本身，而是感知模块与全身控制系统之间的接口构建与任务闭环验证。通过在 CyboRacket 和 OpenClaw 两类任务中进行系统级集成，本文验证了从感知结果到全身动作执行的统一控制链路。

第三节　本文主要研究内容

本文围绕“数据采集–控制策略–任务执行”三层主线展开研究，目标是建立一套可支撑人形机器人全身运动控制与自主任务执行的统一框架。具体而言，本文的主要工作包括以下三个方面。

第一，面向遥操作和具身数据采集需求，构建多源异构人体运动捕捉体系，涵盖 Noitom 惯性动捕、Nokov 光学动捕和基于 SONIC 的仿真交互数据。针对人体与机器人之间的形态差异，设计基于 GMR 的动作重定向方法，将人体动作转换为机器人可执行的关节轨迹或末端目标。

第二，针对人形机器人全身控制中移动与操作相互耦合的问题，提出上下肢解耦的通用控制架构。下肢部分基于强化学习训练 Locomotion 策略，以获得稳定的基础移动能力；上肢部分构建面向遥操作和自动规划结果的统一轨迹接口，并结合逆运动学实现高保真跟踪；同时引入全身协调机制，用于处理上肢大范围动作对下肢稳定性的影响。

第三，围绕感知驱动的任务级应用，构建感知–控制闭环系统，并在动态球拍任务与语音指令服务任务中开展验证。通过将视觉感知、任务规划与全身控制接口统一起来，本文展示了所提方法在动态目标交互和服务型具身任务中的应用潜力。

第四节　论文组织结构

全文共分为五章，并附录相关硬件与训练配置说明。

第 1 章为绪论，介绍课题研究背景、相关研究现状、本文主要研究内容以及论文整体结构。

第 2 章讨论多源遥操作数据采集与重定向问题，重点介绍多源运动捕捉体系、动作重定向建模方法以及重定向精度评估思路。

第 3 章介绍解耦式通用全身运动控制策略，重点阐述上下肢解耦架构、下肢强化学习 Locomotion 策略、上肢轨迹跟踪接口以及 Sim-to-Real 真机验证方法。

第 4 章给出感知–控制闭环自主任务执行的系统实现，选取 CyboRacket 和 OpenClaw 两个任务作为验证案例，展示感知、规划与全身控制的系统级融合方式。

第 5 章总结全文工作，归纳主要创新点，并对未来研究方向进行展望。

第二章　多源全身运动数据采集与重定向

第一节　系统架构概述

为了支撑人形机器人的全身运动控制与任务级行为学习，需要采集机器人本身的动作数据以及与环境交互的数据，提供类人运动的先验知识，以便于进行强化学习、模仿学习等。而机器人本体运动数据又很难获得，人类动作数据虽然容易获取，但人体与机器人的骨骼结构存在差异，需要将人体动作映射为机器人可执行的关节轨迹或末端目标，此为重定向问题。

所以为了解决“数据从哪里来”和“如何稳定映射到机器人”这两个基础问题，本章构建了多源全身运动数据采集与重定向系统。数据采集模块负责从不同设备获取操作者的姿态、关节角和轨迹信息，重定向模块负责将人体动作映射为机器人可执行的关节轨迹或末端目标。

多源数据采集的主要原因在于不同实验场景对数据精度、部署效率和任务类型的要求差异显著。惯性动捕适合快速部署和大范围日常采集，光学动捕能够提供更高精度的科研数据，而机器人-物体交互数据能够描述机器人与环境交互过程中的复合动作模式。

在整体流程上，操作者的人体动作首先由采集设备转换为人体姿态表示；随后系统在统一骨架模型与坐标系下进行预处理，并根据具体机器人平台建立从人体空间到机器人空间的映射；最后，通过基于 GMR 的重定向策略生成满足关节限幅和运动约束的机器人可执行数据。如图 2.1 所示，Noitom 惯性动捕与 Nokov 光学动捕两类人体运动数据统一汇入 GMR 模块，并进一步映射到 Unitree G1 与全尺寸机器人平台，从而形成多源数据到多机器人平台的统一重定向链路。

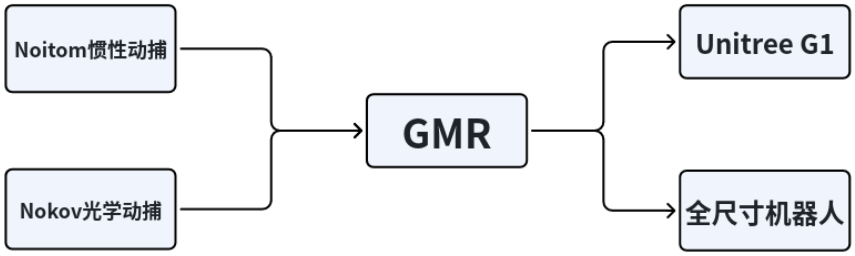

图 2.1　多源动捕数据到机器人平台的 GMR 重定向框架示意图

第二节　多源人体运动捕捉系统

一、惯性动捕系统

Noitom 惯性动捕系统采用穿戴式惯性测量单元获取人体各关键骨骼段的姿态变化，具有部署方便、对场地依赖低和成本相对可控等优势。对于需要快速采集示教动作、重复采集日常操控行为或在非标准实验环境中开展测试的场景，惯性动捕系统能够提供较高的实用价值。本文将其作为常规遥操作数据采集的重要组成部分，重点服务于基础上肢动作、全身协调动作以及初步行为演示数据的积累。

尽管惯性动捕在可部署性方面表现突出，但其在长时间采集时可能存在漂移累积、局部姿态解算误差以及磁场环境敏感等问题。因此，在数据接入阶段，本文对原始关节角序列进行了统一时间戳对齐和平滑处理，并在映射前加入异常帧检测与短时插值，以提升下游重定向的稳定性。对于需要更高精度的位置级分析的实验，惯性动捕数据更多用于提供全身动作趋势与相对姿态信息。

二、光学动捕系统

Nokov 光学动捕系统通过多相机协同跟踪反光标记点，可较高精度地恢复人体关键部位的三维位置与姿态信息。与惯性动捕相比，光学动捕更加适合对末端轨迹误差、关节运动一致性和重定向精度进行定量分析，因此在需要精确评价动作还原质量和系统性能的实验中具有重要作用。

本文利用光学动捕系统采集了面向机器人操作与协调动作的高精度示教数据，并将其作为重定向算法评估的重要基准数据来源。为了便于与机器人控制接口衔接，本文将光学动捕输出进一步转换为统一骨架节点位姿表示，并对关键末端执行器轨迹进行重采样和速度约束处理。这样既能保留高精度空间信息，又能避免直接使用离散点序列时出现的轨迹抖动问题。

需要指出的是，光学动捕系统对场地布局、相机标定质量和遮挡情况较为敏感，因此其更适合用于实验室条件下的标准化采集。本文通过将光学动捕与惯性动捕相互补充，在保证高精度验证能力的同时兼顾了系统整体的采集灵活性。

三、机器人-物体交互数据采集

除人体动作采集外，本研究还基于 SONIC 框架进行机器人-物体交互数据采集。SONIC 是一个全身运动控制框架，基于其稳定、灵活的控制接口，可以方便

地进行机器人-物体交互数据采集。利用 PICO 基于 SONIC 框架进行宇树 G1 机器人全身遥操作、移动操作一体化数据采集，主要采集了三路数据：

1. PICO 遥操作端：记录上游人体动作数据；
2. 宇树 G1 机器人本体：记录机器人本体运动数据；
3. 相机图像链路：记录机器人与物体交互过程中的图像信息；

为了统一说明机器人–物体交互数据采集中的多模态日志结构，表 2.1 对三路数据中具有代表性的文件、关键字段及其用途进行了整理。该表既可作为后续数据对齐与预处理的依据，也可作为训练与评测阶段选择输入模态时的参考。

表 2.1　机器人–物体交互数据采集中的代表性文件与关键字段

代表文件	关键字段/内容	说明
遥操作端 (teleop)		
`pose_*.npz`	`frame_vr_position` / `vr_position`	左手、右手、头/颈等关键点位置
`pose_*.npz`	`frame_vr_orientation` / `vr_orientation`	关键点四元数
`pose_*.npz`	`body_quat_w`	身体朝向
`pose_*.npz`	`joint_pos`	teleop 侧生成的 joint 向量
`pose_*.npz`	`frame_left_hand_joints` / `frame_right_hand_joints`	手部角度
G1 机器人本体 (deploy_logs)		
`q.csv`	29D body joints	机器人关节状态主来源
`left_hand_q.csv` / `right_hand_q.csv`	手部关节	hand state
`base_quat.csv`	base IMU quaternion	姿态、FK 输入
`base_ang_vel.csv`	IMU gyro	robot state IMU
`base_accel.csv`	IMU accel	robot state IMU
`motor_torque.csv`	29D torque	`tau_ff`
`torso_quat.csv`	torso quaternion	`torso_rpy`、`torso_dyaw`
`torso_ang_vel.csv`	torso angular velocity	`torso_vyaw`，积分得到 `target_yaw`
`command_velocity.csv`	`vx`/`vy`/`vyaw` command	planner/locomotion 命令
`command_height.csv`	torso height command	planner 高度命令
`command_heading.csv`	`target_yaw` / `delta_heading`	planner 朝向命令
相机图像链路 (images)		
`images/index.jsonl`	`frame_id`、`timestamp_monotonic`、`streams`	图像索引，不存像素本体
`images/rgb/*.jpg`	RGB 图像	视觉观测
`images/depth/*.npy`	depth	深度观测

从上述数据组织可以看出，遥操作端主要提供人体动作先验，部署日志主要提供机器人本体状态与控制命令，而图像链路则补充环境与目标物体的视觉观

测。三者共同构成了后续全身控制学习、离线回放分析和机器人–物体交互建模的数据基础。

第三节　基于 GMR 的重定向

一、GMR 算法介绍

本文在 General Motion Retargeting（GMR）框架基础上实现人体动作到人形机器人关节空间的重定向。其核心思想并非直接复制人体关节角，而是先将不同来源的人体动作统一表示为标准化骨架帧，再结合机器人运动学模型和逆运动学任务求解机器人当前时刻的可执行位姿。通过这种方式，人体动作中的空间位姿信息能够在保留主要运动趋势的前提下映射到不同结构的人形机器人平台。

在具体实现中，GMR 的输入为单帧人体骨架数据，其数据结构由人体关节名称索引，内容包含关节位置与四元数姿态。系统首先依据人体根节点对动作数据进行尺度归一化，并根据预设的人体骨架缩放表对躯干、上下肢等关键部位进行长度修正，以减小不同操作者身高差异对重定向结果的影响。随后，系统加载目标机器人的 MuJoCo 模型以及相应的 IK 配置文件，从而获得机器人根节点定义、人体与机器人关键刚体之间的对应关系、位置偏置、姿态偏置以及各任务项的权重设置。

在求解阶段，GMR 将人体关键骨骼的目标位姿转换为机器人刚体的跟踪任务，并构建两阶段逆运动学问题。第一阶段主要保证根节点、下肢和躯干等主体结构的稳定对齐，第二阶段进一步细化上肢和末端姿态，从而在整体稳定性和局部精度之间取得平衡。每一帧重定向结果最终以机器人广义坐标 *qpos* 的形式输出，包括根位置、根姿态以及各关节自由度角，为后续动作回放、在线控制与策略学习提供统一接口。

二、基于 GMR 的多源数据重定向实现

在本文的系统中，GMR 不仅作为一个通用重定向求解器存在，更承担了多源人体运动数据统一接入的核心作用。针对不同采集设备的数据格式差异，本文分别实现了 Noitom 动捕数据的离线重定向链路和 Nokov 光学动捕数据的实时重定向链路，使得不同来源的人体动作能够在统一框架下转换为机器人可执行轨迹。

对于 Noitom 动捕数据，本文主要采用离线 BVH 文件重定向方式。首先读取

Noitom 导出的 BVH 文件，并通过骨架解析和前向运动学计算恢复各骨骼节点在全局坐标系下的位置与姿态；随后对不同来源 BVH 文件的坐标系、尺度单位和脚部关键点定义进行统一整理，将其转换为 GMR 所要求的人体骨架帧表示；最后将处理后的数据送入重定向模块，得到目标机器人对应的根位姿和关节轨迹。该离线链路适用于动作数据集构建、示教动作回放以及重定向效果分析。

对于 Nokov 光学动捕数据，本文进一步实现了实时重定向流程。系统通过实时订阅 Nokov 输出的数据帧，读取当前时刻各人体刚体片段的位置与姿态信息，并将其在线转换为与 BVH 路径一致的标准化人体骨架格式。之后，系统在每个时刻调用 GMR 模块求解机器人当前关节配置，并将输出结果送入可视化或下游控制接口。相较于离线 BVH 路径，该方案省去了动作导出与后处理的中间环节，能够满足实时演示、在线调试和遥操作场景下的重定向需求。

综上，本文在 GMR 框架下打通了 “离线 BVH” 与 “实时流数据” 两类重定向链路，实现了 Noitom 和 Nokov 两种主要动捕来源的统一接入。这一工作保证了第 2 章数据采集层与后续机器人控制层之间的数据表示一致性，也为不同任务场景下的人体动作迁移提供了稳定基础。

三、多平台适配：G1 与 Taihu 全尺寸机器人

除多源数据接入外，本文还在同一套 GMR 主框架下完成了面向不同机器人平台的重定向适配。平台适配的关键不在于重新设计重定向求解器，而在于针对不同机器人模型建立对应的 MuJoCo 运动学模型与 IK 配置文件，使人体骨架目标能够映射到具体平台的根节点、躯干、上下肢及末端刚体上。

对于 Unitree G1 平台，本文基于其标准人形结构建立了与 GMR 相匹配的机器人模型和关节映射关系。通过在 IK 配置中定义人体骨架节点与 G1 关键刚体之间的对应关系，并设置相应的位置权重、姿态权重以及偏置参数，系统能够较稳定地完成从人体动作到 G1 关节空间的重定向。该平台构成了本文遥操作与全身动作迁移实验的主要验证对象。

在此基础上，本文进一步面向 Taihu 全尺寸机器人构建了专用的 IK 配置文件。与 G1 相比，Taihu 在机器人根节点命名、关节结构和刚体布局上均存在明显差异，因此需要重新定义人体根节点到机器人根节点的对应关系，并重新设置骨架缩放表、位置偏置、姿态偏置以及两阶段 IK 匹配表中的任务项。通过这些平台专用参数的调整，本文将同一套 GMR 重定向流程迁移到全尺寸机器人上，实现了跨平台的人体动作映射。

因此，本文的多平台适配策略可以概括为“统一重定向框架 + 平台专用配置文件”。该策略既保留了 GMR 框架在算法层面的统一性，又通过配置层的灵活调整满足了不同机器人平台的结构差异，从而降低了系统在多平台部署中的重复开发成本。

第三章　解耦式通用全身运动控制策略

第一节　上下肢解耦控制架构设计

人形机器人在执行移动操作任务时，下肢负责维持稳定支撑和完成位姿调整，上肢负责执行抓取、挥拍、交互等精细动作。若将二者完全作为统一端到端控制问题求解，虽然理论上能够获得整体最优解，但在实际训练和部署中往往面临样本复杂度高、奖励设计困难、策略调试成本大以及迁移稳定性不足等问题。基于这一观察，本文提出上下肢解耦的通用全身控制架构，将移动稳定性与操作精度两个核心目标分别建模，并通过接口层实现统一协调。

在该架构中，下肢控制器接收速度命令、姿态目标和部分全身补偿信息，输出双腿关节动作以维持稳定 locomotion；上肢控制器接收来自遥操作模块或任务规划模块的末端目标、轨迹参考和姿态约束，并通过逆运动学和轨迹跟踪方法完成执行；躯干与状态管理模块则负责在上下肢之间同步关键姿态信息、监测质心偏移并触发必要的补偿策略。这样可以在保持系统模块化的同时，降低全身控制问题的求解难度。

从系统实现角度看，解耦架构还具有良好的可扩展性。对于纯遥操作场景，上肢接口可直接接收第 2 章重定向模块输出；对于自主任务场景，上肢接口也可无缝接收由视觉感知和高层规划器生成的末端目标。下肢控制器则可以在不同任务之间共享同一套基础移动能力，从而避免在每个任务中重复训练整套全身策略。解耦式通用全身运动控制架构如图 3.1 所示。

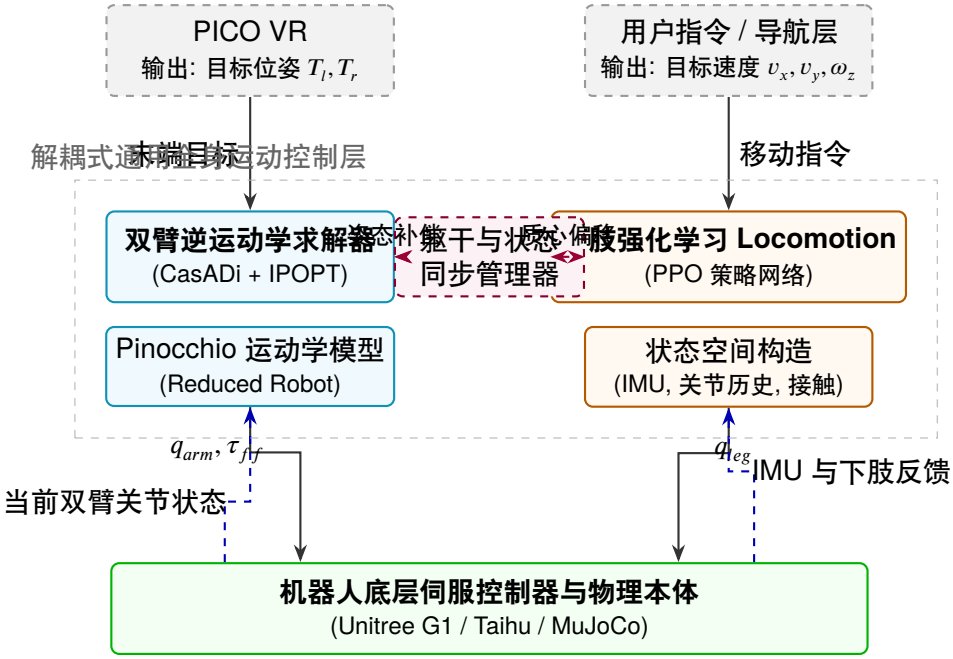

图 3.1　解耦式通用全身运动控制架构图

第二节　上肢遥操作

一、系统组成与数据流

在本文提出的上下肢解耦控制框架中，上肢模块主要承担精细操作与末端轨迹跟踪任务。与下肢侧强调稳定移动不同，上肢控制更关注末端位姿的准确表达、关节解的连续性以及对不同机器人平台的适配能力。为此，本文基于 PICO 设备构建了上肢遥操作系统，并将其与双臂逆运动学求解器及机器人控制器连接起来，形成从操作者动作输入到机器人双臂执行的完整链路。

该系统整体可划分为三个部分。第一部分为遥操作输入模块，负责通过 XR 设备实时获取操作者双臂运动状态，并生成左右臂目标位姿；第二部分为逆运动学模块，负责结合目标末端位姿与机器人当前关节状态求解双臂关节角；第三部分为机器人执行模块，负责将求解结果发送至上肢控制器，实现双臂轨迹跟踪。与此同时，机器人头部图像通过图像链路回传到遥操作端，为操作者提供第一视角反馈，从而构成闭环遥操作界面。

从主程序实现流程来看，系统在每个控制周期内首先读取 XR 设备输出的左右臂目标位姿，再读取机器人当前双臂关节位置和速度作为逆解初值与状态反馈；随后调用双臂逆运动学模块求解当前时刻的目标关节角及前馈力矩；最后由上肢控制器将这些结果下发给机器人。通过这一流程，本文实现了“人体动作输

入–机器人状态反馈–逆解求解–控制执行”的闭环上肢遥操作链路。

二、基于 PICO 的双臂目标位姿获取

本文采用 PICO 作为上肢遥操作输入设备，基于 `Vuer` 框架构建了底层的双向数据通信与位姿获取模块。为了保证机器人控制主循环的高频实时性，并有效处理跨系统的坐标系差异，本模块在工程实现上重点解决了网络通信、并发数据同步以及跨域坐标系转换三个核心问题。

在网络通信方面，系统在底层以独立进程启动 XR 服务端。PICO 设备作为客户端，通过无线网络与服务端建立 WebSocket 连接，将高频的头部相机位姿、手柄控制器状态以及手部追踪数据，以事件流的形式（如 `CONTROLLER_MOVE` 或 `HAND_MOVE`）异步发送至服务端。服务端接收到这些事件后，利用回调机制实时解析操作者的多维度动作指令。

在多进程并发与共享内存同步方面，由于网络 I/O 存在不可避免的波动和延迟，若将其与机器人控制循环耦合，极易导致控制频率不稳定。为此，本文将 XR 服务端放置在独立的后台进程中运行。服务端在解析出目标位姿矩阵与按键状态后，将其写入带有进程锁的共享内存区域（如 `multiprocessing.Array` 和 `Value`）；主控制进程则在每个控制周期直接从共享内存中以非阻塞的方式读取最新数据，从而实现了遥操作输入与底层控制频率的有效解耦。

在跨系统坐标系映射与基座平移方面，由于 PICO 采集的原始空间数据遵循 OpenXR 规范（以 Y 轴朝上为标准），而机器人本体运动学模型遵循标准 URDF 规范（以 Z 轴朝上为标准），两者无法直接混用。系统的 `TeleVuerWrapper` 接口模块负责执行基础的坐标系映射矩阵乘法，完成空间基底与初始姿态的对齐。此外，XR 空间的原点通常与操作者的头部相机初始位置绑定，而双臂逆运动学求解以机器人的腰部（Waist）关节为基座坐标系。因此，该模块还会基于机器人尺寸参数自动完成从头部到腰部的空间平移补偿，最终将标准化、基于腰部基座的齐次变换矩阵作为双臂目标位姿提交给逆运动学求解器。

这种基于统一末端位姿的遥操作架构具有两方面优势：首先，位姿描述与具体机器人关节结构解耦，更适合多平台迁移；其次，它在格式上与自主任务规划模块生成的空间目标完全一致，实现了人工操作与自主规划在控制接口层面的无缝共享。此外，机器人头部相机图像也可通过该网络链路实时回传至 XR 设备，为操作者提供第一视角的闭环视觉反馈。PICO 遥操作输入与主程序通信的整体数据流如图 3.2 所示。

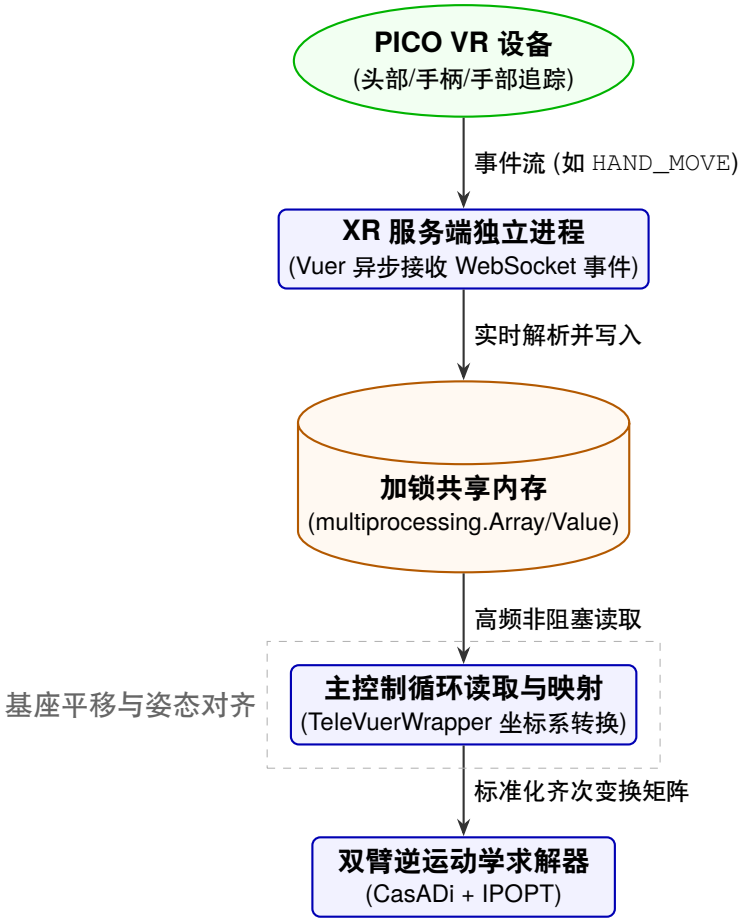

图 3.2　PICO 遥操作输入与位姿获取通信数据流图

三、双臂逆运动学求解方法

在获得左右臂目标位姿后，系统需要将末端空间目标转换为机器人双臂关节空间指令。为此，本文基于 Pinocchio 构建机器人上肢运动学模型，并采用 reduced robot 的方式锁定下肢、腰部以及部分手部关节，仅保留双臂主要活动自由度参与逆运动学求解。通过这种方式，可以在保证双臂可达性的前提下显著降低求解规模，提高实时性与稳定性。

在模型构建完成后，本文分别在左右腕部附近定义左右末端参考帧 L_{ee} 与 R_{ee}，用作双臂末端的操作点。对于给定的左右臂目标位姿，系统构建包含位置误差、姿态误差、正则项和平滑项的优化目标函数：

$$J = w_p\|e_p\|^2 + w_r\|e_r\|^2 + w_q\|q\|^2 + w_s\|q - q_{t-1}\|^2, \tag{3.1}$$

其中，e_p 表示左右末端的位置误差，e_r 表示左右末端的姿态误差，q 为当前时刻待求的双臂关节角，q_{t-1} 为上一时刻关节解。位置项与姿态项用于提升末端跟踪精度，正则项用于抑制过大的关节偏移，平滑项则用于保证相邻时刻求解结果的连续性，从而减小遥操作过程中的抖动现象。算法 3.1 给出了双臂逆运动学的核

心求解流程。

算法 3.1 双臂逆运动学求解流程

Input: 左臂目标位姿 T_l，右臂目标位姿 T_r，当前关节状态 q_{t-1}

Output: 双臂目标关节角 `sol_q`，前馈力矩 `sol_tauff`

1 读取机器人上肢 reduced robot 模型及关节上下界;

2 在左右腕部定义末端参考帧 L_{ee} 和 R_{ee};

3 将 T_l、T_r 设置为当前时刻逆运动学目标;

4 根据当前关节变量 q 计算左右末端位置误差 e_p;

5 根据当前关节变量 q 计算左右末端姿态误差 e_r;

6 构建目标函数 $J = 50\|e_p\|^2 + \|e_r\|^2 + 0.02\|q\|^2 + 0.1\|q - q_{t-1}\|^2$;

7 在关节限位约束下调用 IPOPT 求解最优关节角 `sol_q`;

8 基于求得的关节角和机器人动力学模型计算前馈力矩 `sol_tauff`;

9 输出 `sol_q` 和 `sol_tauff`;

在求解器实现上，本文采用 CasADi 建立符号优化问题，并调用 IPOPT 进行数值求解。为保证求解结果满足机器人硬件约束，优化过程中显式加入关节上下界约束。最终，逆运动学模块输出双臂目标关节角 `sol_q`，并结合机器人动力学模型进一步计算逆动力学前馈力矩 `sol_tauff`。这一设计使得上肢控制器不仅能够根据目标末端位姿产生关节位置指令，还能够通过前馈补偿提高跟踪执行的稳定性。

四、Taihu 平台迁移与仿真验证

在 Unitree G1 平台实现双臂遥操作与逆运动学求解后，本文进一步将同一套方法迁移到 Taihu 全尺寸机器人平台。迁移过程中，逆运动学的整体建模思路保持不变，核心修改集中在机器人 URDF 模型、关节命名方式、锁定关节集合以及末端参考帧的重新定义上。也就是说，本文并未为 Taihu 单独设计一套新的上肢求解框架，而是在保留“末端位姿输入 + 约束优化求解”这一核心思路的基础上，完成了面向新平台的工程适配。

具体而言，Taihu 平台采用与 G1 不同的关节命名和机械结构，因此系统需要根据 Taihu 机器人上肢的实际关节布局重新定义 reduced robot，并在左右腕部关节附近构造新的末端参考帧。同时，由于全尺寸机器人在臂长、可达空间和关节限位上与 G1 存在差异，原有上肢末端目标在新平台上未必能够直接复用，因此仍需结合具体平台参数对目标位姿和求解约束进行适配。

为降低直接真机调试的风险，本文在 Taihu 平台迁移过程中进一步结合 MuJoCo 与可视化环境对双臂逆解模块进行了验证。通过在仿真环境中输入左右臂目标位姿并观察机器人末端跟踪效果，可以在不上真机的情况下检查求解器在新平台上的可达性、连续性和稳定性。实验表明，本文所采用的上肢遥操作与逆运动学框架具有较好的跨平台复用能力，可为后续全尺寸人形机器人的双臂操作研究提供基础。

第三节　下肢强化学习 Locomotion 策略

为使人形机器人在执行全身任务时具备稳定、连续且可泛化的基础移动能力，本文将下肢控制建模为命令条件下的 locomotion 学习问题，并以 BeyondMimic 所体现的自然运动先验为启发，采用 motion prior 约束下的 imitation 与 reinforcement learning 混合训练框架。与仅依赖低维速度奖励的传统 locomotion 方法不同，本文强调在连续命令驱动下同时保留自然步态结构，使策略不仅能够响应基座速度、姿态偏差和接触变化，还能够在不同运动模式间实现较平滑的过渡。由此，下肢控制器不再被描述为若干离散技能的集合，而是被视为一个统一的 command-conditioned locomotion policy。

一、任务建模与训练环境

本文将下肢命令条件 locomotion 任务建模为马尔可夫决策过程

$$\mathcal{M} = (\mathcal{S}, \mathcal{O}, \mathcal{A}, \mathcal{P}, r, \gamma), \tag{3.2}$$

其中，$\mathcal{S}$ 表示机器人与仿真环境的真实状态空间，$\mathcal{O}$ 表示策略可观测空间，$\mathcal{A}$ 表示动作空间，$\mathcal{P}$ 表示环境状态转移，r 为阶段奖励函数，γ 为折扣因子。设连续运动命令为

$$c_t = \left[v_{x,t}^{\mathrm{cmd}},\ v_{y,t}^{\mathrm{cmd}},\ \omega_{z,t}^{\mathrm{cmd}}\right], \tag{3.3}$$

其中，$v_{x,t}^{\mathrm{cmd}}$、$v_{y,t}^{\mathrm{cmd}}$ 和 $\omega_{z,t}^{\mathrm{cmd}}$ 分别表示期望前向速度、横向速度和偏航角速度。策略训练的目标是学习参数化策略 π_θ，使其在命令约束下最大化折扣累计回报：

$$\max_{\theta} J(\pi_\theta) = \mathbb{E}_{\pi_\theta}\left[\sum_{t=0}^{T} \gamma^t r_t\right]. \tag{3.4}$$

与纯命令跟踪策略不同，本文进一步引入来自参考动作数据集的 motion prior，用于约束步态自然性和模式过渡质量。换言之，机器人并不是从零开始学习抽象

的“行走能力”，而是在参考动作先验的引导下学习如何在连续命令变化和外部扰动下生成稳定、自然的 locomotion 行为。

从训练环境组织方式看，本文采用 Isaac Lab 的 manager-based 强化学习框架来承载这一 MDP。环境以平地为基础场景，通过并行仿真同时采样大量机器人实例，并在重置阶段注入根部位置、姿态、速度、接触和动力学参数扰动。训练过程中，高层命令在给定范围内随机采样，而参考动作数据则以 motion prior 的形式提供步态结构约束和 imitation 监督信号。训练对象为 Unitree G1 的全身模型，下肢承担主要 locomotion 功能，隐式 PD 执行器负责将策略输出的关节参考量转换为底层稳定驱动。具体的 PPO 超参数、并行环境规模、仿真时间步长、执行器参数以及动作缩放配置不再在此展开，统一整理于附录表 B.1 与表 B.2。

为更清晰展示该策略的训练逻辑，本文将单一命令条件下肢策略的训练流程概括为“命令采样–motion prior 监督–环境交互–PPO 优化–奖励回传”的闭环结构，如图 3.3 所示。

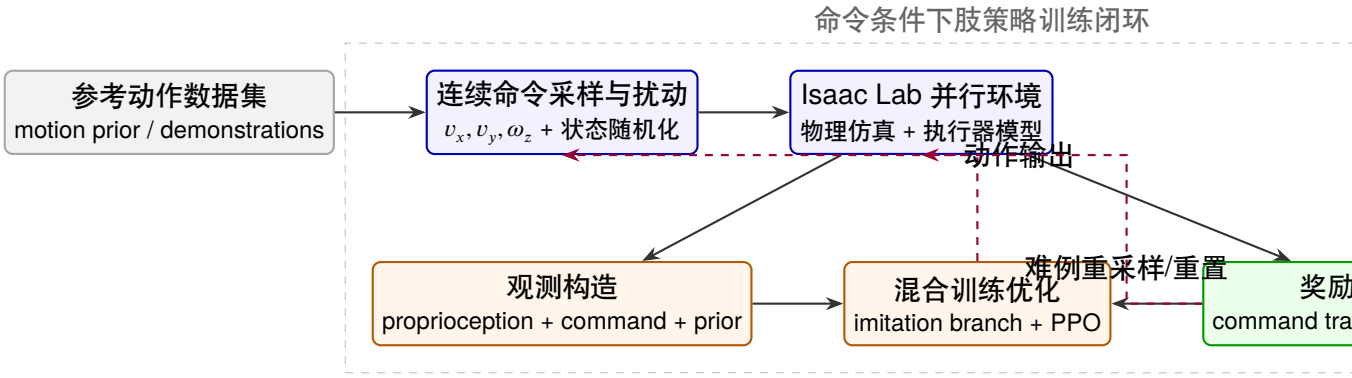

图 3.3　单一命令条件下肢策略训练流程图

二、命令输入、观测与动作设计

在命令条件设计上，本文直接向策略提供低维连续运动命令 c_t，用于刻画当前期望的基座运动意图。同时，为避免策略仅依据速度奖励学习出缺乏自然性的步态，本文引入来自参考动作数据集的 motion prior 条件 h_t^{prior}，其作用不是强制机器人逐帧复现某一条轨迹，而是为策略提供关于步态相位、姿态变化趋势和局部运动风格的先验约束。由此，策略在训练时既接收连续命令，又保留来自示教数据的自然运动偏好。

在本文记号下，actor 的输入可记为

$$o_t = \left[c_t,\ h_t^{\text{prior}},\ v_t^{\text{base}},\ \omega_t^{\text{base}},\ q_t - q_0,\ \dot{q}_t,\ a_{t-1}\right], \tag{3.5}$$

其中，h_t^{prior} 表示由参考动作先验提取的步态上下文特征，v_t^{base} 与 ω_t^{base} 分别表

示机身线速度和角速度，$q_t - q_0$ 为相对默认姿态的关节偏移，a_{t-1} 为上一时刻动作。该观测设计使策略在每个时刻同时感知连续控制命令、当前机身运动状态、历史控制趋势以及自然步态先验。为提升 sim-to-real 鲁棒性，训练过程中还在这些观测量上叠加均匀噪声，其具体范围统一列于附录表 B.3。

对于 critic，本文采用非对称 actor-critic 结构，在训练阶段向值函数网络额外提供关键刚体相对躯干的真实位置与姿态等特权信息，从而得到更稳定的值函数估计。在本文记号下，critic 的输入可进一步写为

$$\tilde{o}_t = \left[o_t,\ p_t^{\text{body}},\ R_t^{\text{body}}\right]. \tag{3.6}$$

其中，p_t^{body} 表示各关键刚体相对躯干锚点的真实位置量，R_t^{body} 表示对应相对姿态的 Rot6D 编码。相较于欧拉角表示中的周期性跳变以及四元数表示中的双覆盖歧义，Rot6D 通过旋转矩阵前两列构造连续的姿态编码，使相近姿态在特征空间中仍保持相近表示，从而改善了策略网络回归过程中的损失平滑性与优化稳定性。该设计兼顾了部署阶段的部分可观测约束与训练阶段的估计精度需求。

在动作设计方面，策略输出及其到关节参考量的映射可概括为

$$a_t = \pi_\theta(o_t), \tag{3.7}$$

并进一步写为关节位置参考量

$$q_t^{\text{sp}} = q_0 + \alpha \odot a_t, \tag{3.8}$$

其中，α 为按执行器能力设置的关节缩放系数。也就是说，策略并不直接输出力矩，而是生成目标关节位置增量，再由底层隐式 PD 执行层完成力矩闭环。这样既降低了策略直接学习复杂接触动力学逆模型的难度，又保留了执行器侧的稳定性与物理约束。

三、奖励函数与终止条件设计

奖励函数设计是本文单一命令条件下肢策略训练的核心。为使机器人既能准确响应连续命令，又能保持自然、稳定的步态结构，本文将阶段奖励划分为命令跟踪项、稳定性项、先验一致性项和正则惩罚项。首先，平面速度与偏航角速度的命令跟踪误差可写为

$$\bar{e}_v = \left\| \begin{bmatrix} v_{x,t} \\ v_{y,t} \end{bmatrix} - \begin{bmatrix} v_{x,t}^{\text{cmd}} \\ v_{y,t}^{\text{cmd}} \end{bmatrix} \right\|_2^2, \qquad \bar{e}_\omega = \left|\omega_{z,t} - \omega_{z,t}^{\text{cmd}}\right|^2, \tag{3.9}$$

其中，$v_{x,t}$、$v_{y,t}$ 和 $\omega_{z,t}$ 分别表示机器人当前时刻的前向速度、横向速度与偏航角速度。为约束机身稳定性，进一步定义躯干高度与姿态偏差：

$$\bar{e}_h = \left|h_t - h_0\right|^2, \qquad \bar{e}_R = d\left(R_t^{\text{torso}}, R_0^{\text{torso}}\right)^2, \tag{3.10}$$

其中，h_t 表示当前躯干高度，h_0 表示名义站立高度，R_t^{torso} 与 R_0^{torso} 分别表示当前和名义躯干姿态，$d(\cdot,\cdot)$ 表示姿态距离。另一方面，为保留参考动作数据中的自然步态结构，本文引入 imitation / motion prior 一致性误差

$$\bar{e}_{\text{im}} = \left\|a_t - a_t^{\text{prior}}\right\|_2^2, \tag{3.11}$$

其中，a_t^{prior} 表示由 motion prior 或示教轨迹给出的参考动作。为保持各奖励项尺度一致，本文使用指数型塑形函数将上述误差映射为有界正奖励：

$$r_s = \exp\left(-\frac{\bar{e}_s}{\sigma_s^2}\right), \qquad s \in \{v, \omega, h, R, \text{im}\}. \tag{3.12}$$

其中，σ_s 为对应奖励项的尺度参数，用于控制误差到奖励衰减的敏感程度。

综合各项正向奖励与正则项后，阶段奖励可写为

$$\begin{aligned} r_t = {} & w_v r_v + w_\omega r_\omega + w_h r_h + w_R r_R + w_{\text{im}} r_{\text{im}} \\ & - \lambda_u \left\|a_t - a_{t-1}\right\|_2^2 - \lambda_l r_{\text{limit}} - \lambda_c r_{\text{contact}}, \end{aligned} \tag{3.13}$$

其中，r_t 为时刻 t 的阶段奖励，r_v 和 r_ω 分别表示线速度与偏航角速度命令跟踪奖励，r_h 与 r_R 表示机身高度和姿态稳定性奖励，r_{im} 表示与 motion prior 保持一致的 imitation 奖励；w_v、w_ω、w_h、w_R 和 w_{im} 为各正向奖励项的权重；a_t 和 a_{t-1} 分别为当前时刻与上一时刻的策略动作；λ_u、λ_l 和 λ_c 为动作平滑项、关节越限项和非期望接触项的惩罚系数；r_{limit} 表示关节越限惩罚，r_{contact} 表示非期望接触惩罚。上述设计对应了“命令响应–姿态稳定–运动自然性–物理可行性”的四层训练目标。各奖励项的具体设计项、观测噪声范围及终止阈值整理于附录表 B.3。

终止条件同样围绕机身失稳和命令执行失效进行设计。若躯干高度偏差、躯干姿态偏差或非期望碰撞超过阈值，则提前结束当前回合。其逻辑可概括为

$$d_t = \mathbb{I}\left(\left|h_t - h_0\right| > \delta_h \ \vee \ d\left(R_t^{\text{torso}}, R_0^{\text{torso}}\right) > \delta_R \ \vee \ r_{\text{contact}} > \delta_c\right), \tag{3.14}$$

其中，$\mathbb{I}(\cdot)$ 为示性函数，当括号内任一条件成立时取值为 1，表示当前回合终止；δ_h、δ_R 和 δ_c 分别表示躯干高度阈值、躯干姿态阈值和非期望接触阈值。这样的提前终止机制能够避免策略在严重跌倒状态中浪费采样步数，并将训练重点集中到可恢复、可学习的命令响应区域。

此外，为提高训练覆盖度，本文在连续命令空间上采用分段采样与课程式扩展策略：训练初期优先覆盖低速、小转角命令，随后逐步扩展到更大范围的前进、

后退、横移和转向命令，从而提高单一策略在完整命令空间中的收敛稳定性。

四、策略优化与训练配置

在策略优化算法上，本文采用 imitation 与 PPO 结合的混合训练框架。对于强化学习部分，仍使用 PPO 对策略网络和价值网络进行联合优化，其核心裁剪目标可写为

$$L^{\text{clip}}(\theta) = \mathbb{E}_t \left[\min\left(\rho_t(\theta)\hat{A}_t,\ \text{clip}\left(\rho_t(\theta), 1-\epsilon, 1+\epsilon\right)\hat{A}_t\right)\right], \tag{3.15}$$

其中，

$$\rho_t(\theta) = \frac{\pi_\theta(a_t|o_t)}{\pi_{\theta_{\text{old}}}(a_t|o_t)}, \tag{3.16}$$

$\hat{A}_t$ 为优势估计。为保留 motion prior 所蕴含的自然步态结构，本文进一步引入 imitation 损失

$$L_{\text{im}} = \mathbb{E}_t \left[\left\|a_t - a_t^{\text{prior}}\right\|_2^2\right], \tag{3.17}$$

并将整体训练目标写为

$$L_{\text{total}} = L_{\text{RL}} + \lambda_{\text{im}} L_{\text{im}}, \tag{3.18}$$

其中，L_{RL} 表示由 PPO 裁剪目标、价值函数损失与熵正则共同构成的强化学习优化项，λ_{im} 为 imitation 分支权重。该写法刻画的是一种典型的混合训练思路：一方面利用 imitation / motion prior 约束策略保持自然运动风格，另一方面通过 PPO 提升其在扰动、接触不确定性和连续命令变化下的鲁棒性。由于本文采用非对称 actor-critic 结构，actor 仅依赖可部署观测，而 critic 在训练阶段使用特权观测，这种设置能够在不增加部署复杂度的前提下提高训练稳定性。

PPO 的学习率、批大小、epoch 数、clip 系数、熵正则、KL 约束，以及并行环境数、控制周期、网络层数等具体配置统一整理在附录表 B.1 和表 B.2 中。

五、单一命令条件策略与训练效果

在单一命令条件策略的设定下，前进、后退、横移与转向不再被视为彼此独立的控制器，而是被统一纳入同一策略在不同命令条件下的输出分布中。换言之，本文希望学习的是一个连续命令驱动的 locomotion 生成器：当命令 c_t 变化时，策略能够自动在前进、后退、侧移与原地转向等动作模式之间调整输出，而不是依赖显式的离散模式切换。

在本文记号下，该单一策略的动作生成过程可概括为

$$a_t = \pi_\theta(o_t, c_t, h_t^{\text{prior}}), \tag{3.19}$$

其中，c_t 表示连续运动命令，h_t^{prior} 表示 motion prior 条件。该表达强调：不同 locomotion 模式的形成来源于连续命令与运动先验的共同作用，而不是由独立策略的显式切换触发。由此，策略在小命令变化下也能给出相邻的动作响应，有利于实现更平滑的速度调节与模式过渡。

从训练效果的角度看，单一命令条件策略的优势在于：其一，连续命令空间内的不同运动模式共享同一套网络参数，有利于在前进、后退、横移和转向之间形成统一的动力学表征；其二，motion prior 与 imitation 约束为策略提供了自然步态偏好，使其在命令变化时仍能保持较好的人形运动风格；其三，命令空间中的中间状态不再需要依赖手工划分的模式边界，而能够通过同一策略自然生成速度过渡与姿态调整行为。

训练曲线图预留位置

可用于展示单一命令条件策略在命令空间扩展过程中的奖励收敛、跟踪误差下降和稳定性结果

图 3.4　单一命令条件策略训练曲线预留图位

仿真效果图预留位置

可用于展示单一策略在不同连续命令下实现前进、后退、横移和转向的仿真运动快照

图 3.5　单一命令条件策略仿真效果预留图位

真机 locomotion 效果图预留位置

可用于展示单一策略在真实机器人平台上对不同连续命令的执行效果

图 3.6　单一命令条件策略真机效果预留图位

综合来看，本文的下肢 locomotion 模块并不是单纯以“速度跟踪”为目标的传统行走控制器，而是一个融合连续命令输入、motion prior、imitation 约束与 PPO 优化的统一基础运动控制器。它在体系结构上与上肢遥操作模块天然解耦：下肢负责生成稳定的全身支撑与基座移动能力，上肢则在其基础上完成精细操作任务。关于命令输入的在线映射方式与整机集成机制，将在下一节进一步讨论。

第四节　系统集成与真机验证

本节进一步从系统实现角度讨论解耦式全身控制策略的部署方式。与上一节聚焦单一命令条件策略的训练不同，本节重点回答两个问题：其一，连续运动命令如何由 PICO 输入映射为下肢控制接口；其二，上肢遥操作输出与下肢移动控制输出如何在整机层面融合，并最终支撑真实任务执行。

一、连续命令输入与 PICO 控制接口

在系统部署阶段，PICO 在下肢部分不再承担“模式切换器”的角色，而是作为连续运动命令输入设备。操作者通过摇杆或手柄状态提供期望的前向速度、横向速度与偏航角速度，系统将其映射为下肢策略的连续命令输入。若记 PICO 控制输入为 u_t，命令映射函数为 $\mathcal{M}(\cdot)$，则在线控制逻辑可写为

$$c_t = \mathcal{M}(u_t), \qquad a_t = \pi_\theta(o_t, c_t, h_t^{\text{prior}}), \tag{3.20}$$

其中，c_t 表示连续 locomotion 命令，$\mathcal{M}(\cdot)$ 表示从人机输入到命令空间的映射关系。该结构将“人机交互意图解析”与“低层 locomotion 动作生成”分离开来，使操作员能够通过连续命令而非离散模式调用机器人移动能力。

从工程实现角度看，这种命令输入方式具有三点优势。首先，PICO 输入与

策略命令空间之间建立了直接对应关系，避免了离散模式切换导致的边界不连续问题。其次，单一策略能够在连续命令变化下自然产生速度调节和模式过渡，从而提升人机交互的流畅性。最后，下肢控制接口被统一为命令驱动形式，更便于与上层任务规划、共享控制和自主导航模块对接。

二、上下肢解耦融合与统一控制输出

在整机控制层，上肢与下肢模块采用“分子空间生成、统一接口下发”的融合方式。其思想与 Psi0 的部署逻辑一致：首先由单一命令条件下肢策略在给定 c_t 的条件下给出与基座移动和支撑调节相关的候选关节命令；随后再利用上肢遥操作与逆运动学结果，对全身命令中的上肢关节片段进行覆盖，从而形成最终的整机控制输出。这样做的核心不在于简单地将两组控制量并列堆叠，而在于通过关节子空间划分，使下肢策略持续负责动态稳定与移动能力，而上肢模块专注于双臂操作任务。

若记下肢策略首先生成的候选全身命令为 $(\bar{q}_t^{\mathrm{wb}}, \bar{\tau}_t^{\mathrm{wb}})$，上肢逆运动学模块输出的双臂命令为 $(q_t^{\mathrm{arm}}, \tau_t^{\mathrm{arm}})$，并以 $\mathcal{J}_{\mathrm{leg}}$ 和 $\mathcal{J}_{\mathrm{arm}}$ 分别表示下肢与上肢关节索引集合，则最终整机控制命令可写为

$$q_t^{\mathrm{wb}}[\mathcal{J}_{\mathrm{leg}}] = \bar{q}_t^{\mathrm{wb}}[\mathcal{J}_{\mathrm{leg}}], \qquad q_t^{\mathrm{wb}}[\mathcal{J}_{\mathrm{arm}}] = q_t^{\mathrm{arm}}, \tag{3.21}$$

$$\tau_t^{\mathrm{wb}}[\mathcal{J}_{\mathrm{leg}}] = \bar{\tau}_t^{\mathrm{wb}}[\mathcal{J}_{\mathrm{leg}}], \qquad \tau_t^{\mathrm{wb}}[\mathcal{J}_{\mathrm{arm}}] = \tau_t^{\mathrm{arm}}. \tag{3.22}$$

其中，q_t^{wb} 和 τ_t^{wb} 分别表示全身关节目标位置与全身前馈力矩，$\bar{q}_t^{\mathrm{wb}}$ 和 $\bar{\tau}_t^{\mathrm{wb}}$ 表示命令条件下肢策略给出的候选全身命令。上述写法所表达的正是“下肢保留下肢子空间输出，上肢覆盖上肢子空间输出”的控制融合机制，它与 Psi0 中先由下肢策略产生候选命令、再将双臂控制结果覆盖到上肢关节片段的实现思路一致。

这种上下肢解耦融合方式的优点在于：一方面，下肢策略无需显式建模复杂的双臂操作意图，从而能够保持步态稳定性与移动鲁棒性；另一方面，上肢遥操作也无需直接关心整机重心调节和落足策略，而只需专注于双臂目标位姿生成。因而，整机系统既保留了强化学习策略在动态稳定方面的优势，也保留了遥操作在精细操作和任务泛化方面的灵活性。

三、真机任务验证

为验证所提出系统在真实场景中的可用性，本文将真机实验从单纯的 locomotion 指标测试扩展到移动操作任务验证。实验中，操作者通过 PICO 设备同时

完成基座机动与双臂遥操作，使机器人在真实环境中执行具有代表性的搬运与整理任务。例如，机器人需要先接近目标物体，再通过双臂抓取水瓶并将其放入指定盒中；在另一项任务中，机器人需要将放置于桌面的书包抓起，并转移至相邻桌面完成重新放置。此类任务同时涉及基座相对定位、双臂姿态协调、抓取稳定性和放置精度，因此能够较全面地检验系统的整体性能。

从验证指标上看，真机任务实验重点关注以下几个方面：其一，机器人在执行移动操作任务时能否保持基座运动稳定，避免在横移、转向或接近目标物体过程中发生明显失稳；其二，上下肢模块能否在控制时序上实现协调，即下肢持续提供稳定支撑，而上肢完成目标抓取与释放动作；其三，整套人机交互系统是否具备足够的实时性与可控性，使操作者能够在任务过程中连续修正动作而不引入明显迟滞。

真机任务验证图预留位置

可用于展示水瓶抓取放置、书包搬运等任务的操作序列图或关键帧结果

图 3.7　系统真机任务验证预留图位

总体而言，本节所述的系统集成过程将“连续命令输入”“上下肢控制融合”和“任务级真机执行”三者贯通起来，使本文提出的解耦式控制框架不仅能够支撑基础 locomotion 能力训练，还能够进一步服务于具有实际操作意义的移动操作任务。

第四章　感知–控制闭环的自主任务执行

第一节　感知–控制闭环架构概述

前两章分别解决了人形机器人全身控制中的数据来源问题和底层控制问题，而要让机器人在开放环境中完成真实任务，还需要将感知、规划与控制整合为闭环系统。本文面向动态交互和服务型任务，构建了统一的感知–控制闭环架构：感知模块负责识别环境状态与目标对象，任务规划模块负责将高层目标转化为结构化动作意图，控制模块则基于第 3 章提出的上下肢解耦控制框架完成具体动作执行，并将执行结果反馈给上层模块用于下一步决策。

该架构的关键不在于替代视觉感知或任务规划算法本身，而在于建立统一的接口规范。对于下肢控制器，上层模块输出目标方向、期望速度或局部导航目标；对于上肢控制器，上层模块输出末端目标位姿、关键轨迹路标点或抓取姿态约束。通过这种方式，来自不同任务的感知与规划结果可以在同一控制框架内复用，从而提高系统的通用性和工程效率。

第二节　动态球拍运动控制任务

一、任务背景与系统架构

CyboRacket 任务面向高速动态目标交互场景，要求机器人在较短时间内完成目标检测、落点预测、移动调整和挥拍动作生成。与静态抓取任务相比，该任务对系统时延、全身协调以及轨迹生成稳定性提出了更高要求：一方面，机器人需要根据高速运动目标的状态实时更新击球策略；另一方面，下肢必须在有限时间内调整站位，上肢则需要在满足可达性约束的同时完成挥拍动作。

在该任务中，本文关注的核心贡献在于全身控制接口与真机部署。视觉感知和轨迹预测模块提供球体状态估计与预期击球点信息，本文则负责将这些中间结果映射到第 3 章所定义的上下肢控制接口中，使机器人能够根据任务需要同时完成移动和挥拍。该过程体现了本文控制框架在动态任务中的可插拔性与闭环执行能力。

二、视觉感知与轨迹预测接口

为了支撑动态球拍任务，视觉系统需要以较高频率对目标进行检测，并通过物理模型或学习模型预测球体未来轨迹。对本文而言，这些感知结果并不直接作用于关节空间，而是被转换为对全身控制器更友好的中间表示，例如预期击球区域、建议机身站位以及击球时刻对应的上肢末端目标。

在下肢侧，预测轨迹被转换为局部导航指令，例如前向速度、横向位移或机身朝向调整需求，以驱动 RL locomotion 策略将机器人移动到合适击球区域；在上肢侧，预测击球点与拍面姿态要求被转化为末端位姿目标，并交由上肢轨迹生成和逆运动学模块求解。通过这种接口标准化方式，视觉模块无需直接考虑机器人全身动力学细节，而控制模块也无需依赖感知算法内部实现。

三、全身运动生成与实验验证

在获得感知输出后，系统首先确定机器人相对于目标轨迹的站位需求，并调用下肢控制器执行位置调整；随后，上肢控制器根据击球点、预期击球方向和时间窗口生成挥拍轨迹；最后，协调模块依据下肢当前支撑状态和上肢动作幅度进行姿态补偿，使机器人能够在移动与挥拍并行时保持整体稳定。

对于仿真验证，本文建议关注击球成功率、拦截位置误差和动作生成时延等指标，以衡量系统在动态任务中的闭环性能；对于真机验证，则应重点考察纯 onboard 感知条件下的持续执行能力、动作重复性和系统恢复能力。由于相关实验统计仍在整理中，本节先保留“目标速度大于 10 m/s、系统总反应时间小于 500 ms”等占位描述，后续可根据最终实验记录进行补全。

第三节　语音指令服务任务执行

一、系统架构与任务流程

除动态交互任务外，本文还面向具身服务机器人场景构建了语音指令服务任务执行系统。该任务以“给我拿瓶水”等自然语言请求为例，要求机器人从高层语义输入出发，完成目标理解、路径规划、目标感知、抓取执行和物品递送等完整流程。与 CyboRacket 相比，该任务对语义理解与多阶段流程组织要求更高，但对全身控制框架的复用同样具有代表性。

在系统实现中，语音输入首先通过飞书 API 或其他交互接口转换为文本指

令，高层规划模块基于 OpenClaw 将用户意图拆解为导航、检测、抓取和递送等结构化子任务；随后，SAM3 等视觉模块负责输出场景分割结果和目标位姿估计；最后，这些任务结果被映射到第 3 章统一控制接口中，以驱动机器人逐步完成任务执行。

二、任务规划与视觉感知

任务规划模块的作用是将高层语义目标转换为控制系统可执行的阶段性任务。例如，“拿瓶水”这一请求可以被分解为接近目标区域、搜索瓶体、定位抓取位姿、抓取目标、移动至交付位置和递送目标等多个阶段。规划器输出的每个阶段既包含动作类别，也包含必要的空间目标与阶段切换条件。

视觉感知模块则负责在各任务阶段提供实时环境信息。在导航阶段，需要识别目标物体或目标区域在环境中的位置关系；在操作阶段，需要输出物体的几何位姿、抓取接触区域和周围障碍物分布；在递送阶段，还需结合人机交互状态确定最终交付姿态。通过将这些信息统一组织为任务阶段约束和末端位姿目标，系统可以顺畅接入本文提出的上、下肢控制框架。

三、全身控制集成与执行

在服务任务执行过程中，下肢控制器负责依据目标方位和路径规划结果生成基础移动行为。对于较简单的近距离任务，可将目标方向直接映射为前进与旋转速度命令；对于需要更复杂避障或局部修正的场景，则可通过局部导航模块先生成中间路径点，再由 RL locomotion 策略完成连续移动。

上肢控制器则根据目标物体位姿和抓取计划生成抓取轨迹，并在抓取后切换到持物递送模式。为保证移动抓取场景下的稳定性，系统会结合第 3 章中的全身协调机制，对机身姿态和重心变化进行补偿。当机器人一边移动一边进行视觉调整或上肢预摆时，该机制能够降低大幅动作对行走稳定性的影响。

四、实验验证

服务任务的实验验证可从任务成功率、平均执行时间、阶段失败原因和人机交互体验等角度展开。对于室内办公环境和 cluttered 桌面等典型场景，系统应重点分析视觉识别失效、抓取失败、移动误差积累以及阶段切换不及时等问题。通过将失败案例划分为感知失败、规划失败和控制失败三类，可以更清晰地定位系统性能瓶颈。

在当前论文初稿中，相关实验数据尚未最终整理，因此本文保留任务成功率、平均执行时长与失败占比等指标占位。后续完成系统测试后，可进一步在本节补充表格和案例图示，并据此分析当前系统在语义理解、复杂环境适应性和长时序任务连续执行方面的局限。

第四节　本章小结

本章围绕两个代表性任务展示了本文方法在感知–控制闭环场景中的应用方式。CyboRacket 任务验证了本文框架在动态目标、高时效要求场景中的全身控制能力，OpenClaw 服务任务则体现了统一控制接口在语义任务执行链路中的适配性。两类任务共同说明，本文提出的技术路线并非局限于离线动作重现，而是能够支撑人形机器人从感知结果到自主动作执行的系统级闭环。

第五章　结论与展望

第一节　本文工作总结

本文围绕人形机器人遥操作与通用全身运动控制问题，尝试建立从数据采集、动作重定向、控制策略生成到任务级闭环验证的完整技术链路。针对传统方法中数据来源单一、全身控制耦合复杂以及任务接口不统一等问题，本文从系统层面对相关模块进行了整合与设计，并给出了一版面向真实任务场景的论文初稿框架。

在数据采集层，本文构建了由 Noitom 惯性动捕、Nokov 光学动捕与 SONIC 仿真交互数据组成的多源异构动作采集体系。该体系兼顾部署灵活性、采集精度和任务复杂度，为人形机器人获取全身运动数据和移动操作示教样本提供了统一入口。针对人体与机器人之间的形态差异，本文进一步建立了基于 GMR 的动作重定向方法，使人体动作能够映射为 Unitree G1 及全尺寸平台的可执行控制目标。

在控制策略层，本文提出了上下肢解耦的通用全身运动控制框架。下肢部分通过单一命令条件策略学习在连续速度命令下实现前进、后退、原地旋转和左右平移等基础 locomotion 能力，并借助 motion prior 与 imitation / reinforcement learning 混合训练保持自然步态结构；上肢部分则通过轨迹接口和逆运动学实现末端目标跟踪，并通过全身协调机制处理重心变化和动作冲突问题。该设计在保留系统模块化优势的同时，兼顾了移动稳定性、操作精度和工程部署可行性。

在应用验证层，本文围绕感知–控制闭环系统开展了两类任务验证。在 CyboRacket 动态球拍任务中，本文重点实现了视觉预测结果到全身控制接口的转换，并验证了机器人在动态目标交互中的全身动作生成能力；在 OpenClaw 语音服务任务中，本文则展示了语义规划、视觉感知和全身控制之间的协同关系，说明所提框架能够服务于多阶段具身任务执行。上述工作共同表明，本文提出的方法具有从遥操作数据采集延伸到自主任务执行的整体潜力。

第二节　主要创新点

1. 提出并构建了面向人形机器人全身控制的多源异构人体运动数据采集与统一重定向框架，将惯性动捕、光学动捕和仿真交互数据纳入同一处理链路，提升了动作数据来源的覆盖能力与可用性。
2. 提出了上下肢解耦的通用全身运动控制架构，将下肢强化学习 locomotion 策略与上肢轨迹跟踪控制有机结合，并通过统一接口实现遥操作与自主任务场景下的控制复用。
3. 验证了从遥操作数据采集、控制策略生成到感知–控制闭环任务执行的完整技术链路，说明所提方法能够支持动态交互任务与服务型具身任务的系统级集成。

第三节　未来工作展望

尽管本文已经初步构建了较完整的人形机器人全身控制框架，但仍有若干方向值得进一步深入研究。

第一，可进一步探索端到端的全身学习方法。在当前解耦架构下，系统已经具备较好的模块化和可解释性，但上下肢间仍主要依赖接口级信息交互。未来可以结合视觉、语言和动作的大模型框架，将解耦模块置于统一优化视角下进行联合训练，以获得更高层次的动作协同性与任务泛化能力。

第二，可拓展到更复杂的长时序任务场景。当前任务验证主要聚焦动态交互和单轮服务执行，未来可考虑多房间导航、多物体连续操作、长期人机协作等复杂任务。此类任务不仅要求底层控制稳定，还要求高层规划、记忆管理和环境建模具备更强能力，因此需要从系统层进行进一步扩展。

第三，可探索视觉–语言–动作模型与全身控制的深度融合。随着 VLA 模型的发展，人形机器人有望通过统一表示完成从自然语言理解到全身动作生成的跨模态推理。如何将这类高层模型输出稳定地映射到底层可执行控制，并保持真机安全性与实时性，将是未来人形机器人研究的重要方向。

总体而言，本文工作为人形机器人遥操作与通用全身运动控制建立了初步框架，但从实验数据完善、系统稳定性提升到任务泛化扩展，仍有较大研究空间。后续工作将围绕这些方向持续推进，以进一步提升人形机器人在真实世界中的自主作业能力。

参 考 文 献

附录 A　硬件平台参数

第一节　Unitree G1 机器人平台

本文实验所涉及的人形机器人平台以 Unitree G1 为主。为便于后续补充正式实验配置，本节先给出参数表的组织方式，并保留关键字段占位。后续可根据实际平台规格填写自由度数量、机身尺寸、关节力矩范围、传感器配置和机载计算资源等信息。

表 A.1　Unitree G1 平台关键参数占位表

参数项	参数值
总自由度	待补充
机身高度/重量	待补充
下肢关键关节配置	待补充
上肢关键关节配置	待补充
IMU/编码器配置	待补充
机载计算单元	待补充

第二节　遥操作与感知设备

除机器人本体外，本文还涉及多种遥操作和感知设备，包括 PICO VR 设备、Noitom 惯性动捕系统、Nokov 光学动捕系统以及 RealSense D455 深度相机等。不同设备分别承担人体动作采集、环境感知和任务交互等功能。建议后续在正式定稿时补充其采样频率、视场角、定位精度、通信时延和标定方式等参数，以支撑实验复现。

附录 B　强化学习训练超参数

第一节　PPO 训练配置

为便于复现实验，本文在本附录中汇总第 3 章单一命令条件下肢策略所采用的核心 PPO 训练配置。由于正文采用的是 motion prior 约束下的 imitation 与 reinforcement learning 混合训练框架，下表主要记录其中强化学习优化部分可沿用的核心参数，包括优化器、采样长度、更新轮数以及策略约束等内容。

表 B.1　PPO 训练超参数配置表

超参数项	参数值
学习率	1×10^{-3}（adaptive schedule）
折扣因子 γ	0.99
GAE 参数 λ	0.95
每环境每轮采样步数	24
PPO 更新轮数	5
Mini-batch 数	4
裁剪系数	0.2
熵正则系数	0.005
价值损失系数	1.0
目标 KL	0.01
梯度裁剪上限	1.0
最大训练轮数	30000
模型保存间隔	每 500 轮

第二节　网络结构与训练环境

除 PPO 核心超参数外，策略网络结构与训练环境配置同样直接影响策略性能。本文采用对称的 actor-critic 多层感知机结构，actor 与 critic 的隐藏层维度均设为 $[512, 256, 128]$，激活函数采用 ELU。训练环境基于 Isaac Lab 搭建，单次并行环境数为 4096，仿真时间步长为 0.005 s，动作降采样系数（decimation）为 4，因此策略控制周期约为 0.02 s；单回合时长为 10 s。对于单一命令条件策略，连

续命令输入与 motion prior 条件会在该环境配置基础上共同参与观测构造和混合训练。

表 B.2　网络结构与训练环境配置表

配置项	参数值
Actor 隐藏层维度	[512, 256, 128]
Critic 隐藏层维度	[512, 256, 128]
激活函数	ELU
并行环境数	4096
仿真时间步长	0.005 s
Decimation	4
策略控制周期	0.02 s
Episode 时长	10 s
环境间距	2.5 m
训练地形	平地
观测形式	Policy 观测 + Critic 特权观测
动作形式	目标关节位置增量

第三节　奖励、观测噪声与终止条件参数

为避免第 3 章正文出现过多工程配置细节，本附录进一步汇总命令跟踪、姿态稳定、motion prior 一致性以及观测噪声和终止条件的设计项。需要说明的是，当前论文版本重点在于阐述单一命令条件策略的训练框架，因此下表对 imitation / motion prior 相关权重以设计项形式给出；而可直接沿用的观测噪声与部分约束项仍参照 BeyondMimic 的 G1 训练配置进行整理。

表 B.3　命令奖励、观测噪声与终止条件参数表

参数项	数值/范围	说明
线速度命令奖励权重 w_v	待定	平面速度命令跟踪项
角速度命令奖励权重 w_ω	待定	偏航角速度命令跟踪项
躯干高度稳定权重 w_h	待定	抑制机身高度偏移
躯干姿态稳定权重 w_R	待定	约束躯干姿态偏差
motion prior 一致性权重 w_{im}	待定	保留自然步态结构
imitation 分支系数 λ_{im}	待定	对应混合训练中的 L_{im}
线速度奖励标准差 σ_v	待定	指数型奖励塑形参数
角速度奖励标准差 σ_ω	待定	指数型奖励塑形参数
高度稳定标准差 σ_h	待定	指数型奖励塑形参数
姿态稳定标准差 σ_R	待定	指数型奖励塑形参数
imitation 一致性标准差 σ_{im}	待定	指数型奖励塑形参数
动作变化惩罚权重 λ_u	待定	对应 $-\lambda_u\|a_t - a_{t-1}\|_2^2$
关节限位惩罚权重 λ_l	待定	抑制关节越限
非期望接触惩罚权重 λ_c	待定	惩罚异常接触
非期望接触阈值 δ_c	待定	接触终止判定阈值
连续命令观测噪声	视设备标定而定	对应 $v_x^{\mathrm{cmd}}, v_y^{\mathrm{cmd}}, \omega_z^{\mathrm{cmd}}$
motion prior 条件噪声	视先验编码方式而定	对应 h_t^{prior}
基座线速度观测噪声	±0.5	`base_lin_vel`
基座角速度观测噪声	±0.2	`base_ang_vel`
关节位置观测噪声	±0.01	`joint_pos`
关节速度观测噪声	±0.5	`joint_vel`
躯干高度终止阈值 δ_h	待定	过大高度偏差提前终止
躯干姿态终止阈值 δ_R	待定	过大姿态偏差提前终止
命令课程扩展阶段	待实验确定	低速到全命令空间的 curriculum 设置

致　谢

本文初稿阶段先保留致谢结构，具体内容将在论文定稿时根据实际指导与合作情况补充完善。

首先，谨向导师及课题组老师致以诚挚感谢。正是在各位老师的指导下，本文得以围绕人形机器人遥操作与全身运动控制这一课题逐步展开。导师在研究选题、技术路线和论文写作方面给予的帮助，将在正式版本中进一步具体说明。

其次，感谢课题组同学和项目合作成员在系统搭建、实验联调和讨论交流中提供的支持。本文涉及多源动作采集、控制策略训练与任务级系统集成，相关工作离不开团队协作与持续迭代。

最后，感谢家人与朋友在学习和研究期间给予的理解与鼓励。后续将在确认致谢名单和表述后，将本节替换为正式定稿内容。

2026 年 4 月